

## Theoretical Part

### PAC learnability

1. כדי להראות ש- $\mathcal{H}$  היא למידת PAC, נראה שעבור אלווריתם  
לומד  $A$  ופונקצית  $m$  התנאי סומר.

נגדיר אלווריתם לומד באופן הבא: בהינתן דגימה  $\{(x_i, y_i)\}_{i=1}^m$   
האלוריתם יחזיר את העיגול  $\hat{r}$  שנותן את המדד הכי קרוב  
לדגימות החיוביות. כלומר  $A$  יחזיר  $h$  כך ש- $\hat{r} = \max_{i: y_i=1} \|x_i\|_2$   
כך שכל דגימה  $x$  בתוך המעגל, הלייבל שלה יהיה 1. ואחרת, 0.  
כעת, נראה שעבור כל מעגל קונצנטרי  $r$  וכל התפלגות  $D$  על  $X$   
ואל  $\varepsilon, \delta \in (0, 1)$  התנאי PAC מתקיים.

נשים לב שעבור המעגל הקטן ביותר מכל בתוך המעגל האמיתי.  
כלומר,  $\hat{r} \leq r$ . כאן שהטעות של האלווריתם יכולה לנבוע רק  
מנקודות שנפלות בקטע  $r \setminus \hat{r}$  אכן

$$L_D(h_S) = P[x \in r \setminus \hat{r}] = P[\hat{r} \leq \|x\|_2 \leq r]$$

נסמן  $L$ - את הקבוצה הבאה:  $L = \{x \in \mathbb{R}^2 : \hat{r} \leq \|x\|_2 \leq r\}$ .

נסמן  $r^*$  - מה עקור כל המקרים של  $\hat{r}$  בהם  $P_{x \sim D}[x \in L] > \varepsilon$

אז נקבל:

$$P_{S \sim D^m}[L_D(h_S) > \varepsilon] = P_{S \sim D^m}\left[\bigwedge_{i=1}^m x_i \notin L^*\right] = \prod_{i=1}^m P_{x_i \sim D}[x_i \notin L^*] \\ \leq (1 - \varepsilon)^m < e^{-\varepsilon m}$$

$$P_{S \sim D^m}[L_D(h_S) \leq \varepsilon] \geq 1 - e^{-\varepsilon m} > 1 - \delta \quad \text{כאשר} \quad L^* = \{x \in \mathbb{R}^2 : r^* \leq \|x\|_2 \leq r\}$$

$\Leftrightarrow$

$$1 - e^{-\varepsilon m} < 1 - \delta \Leftrightarrow -e^{-\varepsilon m} > -\delta \Leftrightarrow e^{-\varepsilon m} \leq \delta$$

$$\Leftrightarrow -\varepsilon m \leq \log(\delta) \Leftrightarrow m \geq \frac{\log(\frac{1}{\delta})}{\varepsilon}$$

## 2.2 VC - dimension

2. נניח בשלילה שמתק"פ:  $VC\text{-dim}(H_1) > VC\text{-dim}(H_2)$   
 נסמן:  $VC\text{-dim}(H_1) = d_1$ ,  $VC\text{-dim}(H_2) = d_2$ . כאן  $d_1 > d_2$ . כעת, מהנתון  $H_1 \subseteq H_2$ , לכן, כל  $H_1$  מקיימת  $H_2$ .  
 ולכן, אם  $d_1$  היא קבוצה של נקודות שמנתצת  $H_1$  אז היא מנתצת  $H_2$ . כלומר מתק"פ  $d_1 = VC\text{-dim}(H_2)$  בסתירה.  
 למה?  $VC\text{-dim}(H_2) = d_2$ . כלומר,  $H_2$  לא יכולה לנתצ קבוצה שגודלה יותר מ- $d_2$ .

3. נוכיח ש-  $d = VC\text{-dim}(H_{con})$  עבור  $d \geq N$ .

• נראה ש-  $d \leq VC\text{-dim}(H_{con})$ :

נבחר את הקבוצה  $d$  כשעבור העיטל  $i$ -א המשתנה  $i$ -א

שווה 1-א והשאר שווים 0-א (עוצמה עבור  $d=4$  נקבע)

(1,0,0,0), (0,1,0,0), (0,0,1,0), (0,0,0,1) (אפשרויות).

אם לכל השמחה של עיבר נוכח עיצור קיטוי קולטני לכל אחד מהשטחים.

אם  $x_i = 1$  ניקח את העיטור  $x_i$ . אחרת, ניקח את הליטל  $\bar{x}_i$ .

באופן כזה, ניצור קיטוי קולטני שמנצל בידיק את כל הנקודות שהעבר שלהם 1 בקבוצה. כלומר  $d \geq \text{vc-dim}(H_{\text{con}})$ .

• כעת, נראה ש-  $\text{vc-dim}(H_{\text{con}}) < d+1$ :

נניח שקיימות  $d+1$  נקודות  $N = \{0,1\}^d$  אולי משוקר היונים, קיימות 2 נקודות שמקבלות את אותה ערך באותה משתנה קולטני.

נסמן ב-  $\hat{x} \neq \hat{y}$  ! כך ש-  $\hat{x}_k = \hat{y}_k$  עבור  $k \in [d]$ .

נשים לב שעבור כל קיטוי קולטני  $\bar{x}_i, x_i$  לא יכולים להופיע ביחד, לכן, לא יהיה ניתן עיצור  $h$  כך שתקדף בין  $\hat{x}$  ל-  $\hat{y}$ . כלומר, לא נוכל לת"ע את כל  $d+1$  הנקודות ע"י  $H_{\text{con}}$ .

סה"כ, קבלנו ש-  $d = \text{vc-dim}(H_{\text{con}})$ .

## 2.3 Sample complexity

4. • מהגדרה: עבור  $\epsilon_1$  נתק"פ:

$$P[L_{D,f}(A(S_m)) < \epsilon_1] \geq 1 - \delta \Leftrightarrow m \geq m_H(\epsilon_1, \delta)$$

ובאופן דומה, עבור  $\epsilon_2$  נתק"פ

$$P[L_{D,f}(A(S_m)) < \epsilon_2] \geq 1 - \delta \Leftrightarrow m \geq m_H(\epsilon_2, \delta)$$

עבור  $m \geq N$  אם  $L_{D,f}(A(S_m)) < \epsilon_1$  אזי  $L_{D,f}(A(S_m)) < \epsilon_2$

כיון ש-  $m = m_H(\epsilon_1, \delta)$  והוא נתק"פ את המשוואה הראשונה

נקרא שחזא את התוצאה השנייה ולכן נקרא:

$$m = m_H(\epsilon_1, \delta) \geq m_H(\epsilon_2, \delta)$$

• מהצד השני, עבור  $\delta_1$  מתקיים:

$$P[L_{D,f}(A(S_m)) < \epsilon] \geq 1 - \delta_1$$

באופן דומה, עבור  $\delta_2$  מתקיים:

$$P[L_{D,f}(A(S_m)) < \epsilon] \geq 1 - \delta_2$$

עבור  $m \geq N$  אם  $P[L_{D,f}(A(S_m)) < \epsilon] > 1 - \delta_1$  אז

$P[L_{D,f}(A(S_m)) < \epsilon] > 1 - \delta_2$  כיון ש-  $m_H(\epsilon, \delta_1) = m$  מתקיים את

המשוואה הראשונה, הוא מתקיים גם את המשוואה השנייה

ולכן נקרא:  $m = m_H(\epsilon, \delta_1) \geq m_H(\epsilon, \delta_2)$

## 2.4 Agnostic PAC

5.  $H$  אינה אגניסטית PAC.

נסתכל על קבוצת  $H$  הקבוצה:  $H = \{0, 1\}^n$  כך ש-  $n \in \mathbb{N}$ .

ראינו בהרצאה שמתקיים  $VC\text{-dim}(H) = \infty$  ולכן אטענה שראינו

בהרצאה  $H$  אינה Agnostic PAC. אבל נשים לב שהתנאי

השאלה מתקיים כי קיימת פונקציה  $h$  כזו של התפלגות  $D$  על  $Z$

קיים אולי  $A$  כך שעבור  $S \sim D^m$  תמיד יחזיר  $h_S = \arg\min_{h \in H} (L_D(h))$

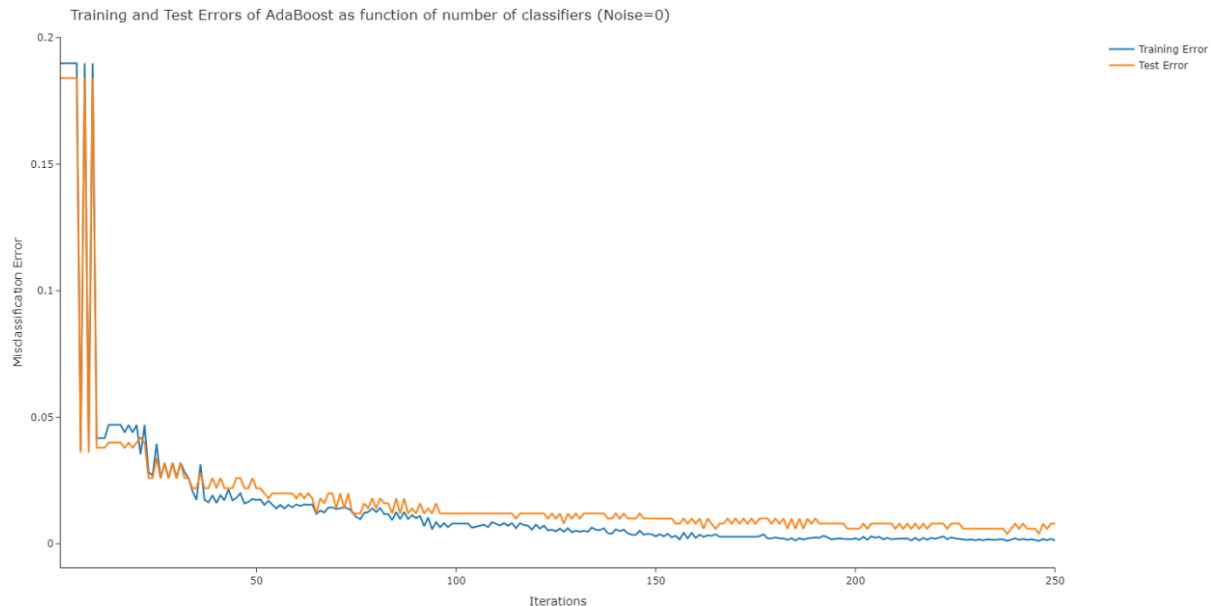
ולכן נקרא:  $L_D(h_S) = \min_{h \in H} (L_D(h)) \leq \min_{h \in H} (L_D(h)) + \epsilon$

בהסתברות 1, כנראה.

## Practical part – IML


### 3.1 boosting

#### 1. Explain your results:



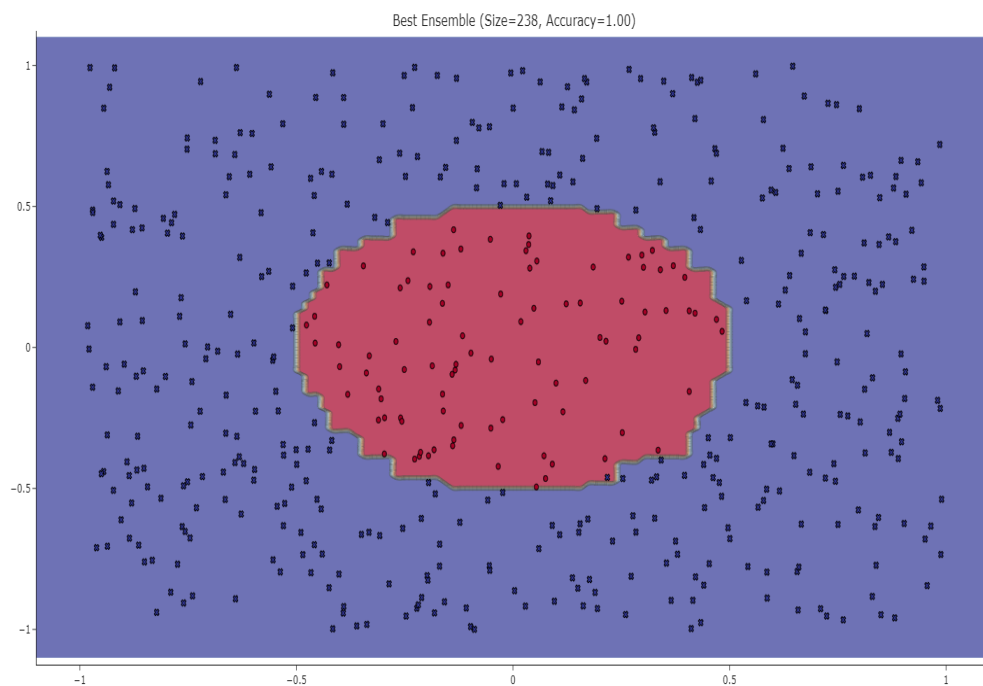
מהגרף נסיק עבור קבוצת האימון וקבוצת הטסט, שככל שקבוצת הלומדים גדלה, הטעות הולכת ושואפת לאפס. הטעות של קבוצת הטסט מעט גבוהה מהטעות של קבוצת האימון אבל עדיין גם היא הולכת ונעשית קטנה.

#### 2. Explain your results:




מהגרף ניתן לראות שככל שמספר הלומדים גדל, כך ההצלחה שלהם לסווג נכון את הנקודות עולה והטעות קטנה. בגרף הראשון של 5 לומדים, הם מצליחים לסווג יחסית טוב אבל ככל שמספר הלומדים גדל, כבר בגודל 50 ניתן לראות שיפור משמעותי וגודל 100 ו-250 הטעות ממש קטנה ושואפת לאפס.

3. size=238, Accuracy=1.00



4. Explain your results, and specifically explain which samples are "easier" and which are more "challenging" for the classifier:


Final AdaBoost Sample Distribution




מהגרף ניתן להבחין איזה נקודות היו קלות ללומדים לסווג ואיזה נקודות היו קשות ללומדים לסווג.

נקודות קטנות בתוך העיגול האדום ומחוצה לו על הרקע הכחול היו קלות לסווג, זאת ניתן לראות ע"י גודל הנקודות. משקלן הוא קטן ולכן הן קטנות. הדגימות שהיו קשות יותר לסווג היו הנקודות שנמצאות על גבול העיגול ושצבען כחול והן בצורת יהלום.

5. Show graphs as in question (1) and question (4). Explain the results. In your answer explain what is seen in the plot of the loss in terms of the bias-variance tradeoff:



Final AdaBoost Sample Distribution



מהגרפים ניתן להבחין בהשפעתו של הרעש של היכולת של הלומדים לסווג את הדגימות.

בגרף (1) הטעות של שני הסטים הולכת ונעשית קטנה ככל שמספר הלומדים גדל אך מדי פעם יש "קפיצות" בגרפים נוצרים מרעש בדגימות. בעוד סט האימון מאיטרציה 50 הולך ושואף לאפס, סט הטסט קופץ מעט, בהתאם לרעש בדגימות. אבל מאיטרציה 250 מתייצב גם הוא אך לא ליד האפס אלא גבוה יותר, בהשפעת הרעש.

באותו אופן, בגרף (4) ניתן להבחין שהרעש מקשה על הלומדים לסווג נכון את הנקודות וניתן לראות זאת על זה שיש חפיפה בין נקודות ממחלקה אחת על מחלקת אחרת ולהיפך.